

Profilazione della coerenza della qualità dell'aria urbana mediante Relaxed Functional Dependencies

Nome Cognome

Matricola: XXXXXXXX

Corso: XXXXXXXX

27 giugno 2026

Sommario

Questo lavoro presenta un'analisi riproducibile della qualità dell'aria urbana come caso di studio per un *Urban Digital Twin* (UDT) concettuale. Il dataset è un sottoinsieme del *Beijing Multi-Site Air Quality Data Set*, limitato alle stazioni Aotizhongxin e Changping nel periodo marzo 2013–febbraio 2017. La scoperta delle *Relaxed Functional Dependencies* (RFDs) usa DiM ϵ , algoritmo esplicitamente trattato nel corso KDIID e descritto da Caruccio, Deufemia e Polese. L'implementazione comprende matrici delle differenze, insiemi di pattern simili stripped, lattice completo degli attributi, insiemi candidati C^+ , pruning e validazione ibrida tramite errore g_3 . Tutte le 66619 osservazioni pulite contribuiscono a una relazione analitica di 1676 righe, formata da mediane settimanali per stazione e fascia oraria sugli otto attributi di scoperta. Con soglie di similarità domain-specific e $g_3 \leq 0.10$, DiM ϵ visita otto livelli, valida 960 candidati e restituisce 5 RFD minime. La regola con confidenza pairwise più alta è **station**, **PM10**, **N02**, **O3**, **TEMP** $\rightarrow$ **WSPM**, con confidenza 0.899, supporto 0.00161, lift 1.163 e $g_3 = 0.092$. Permutation baseline, bootstrap, validazione temporale, continuous profiling e analisi delle violazioni sono applicati esclusivamente dopo la scoperta. Le RFD descrivono regolarità approssimate e non relazioni causali.

1 Introduzione

Nel progetto l'UDT non è una piattaforma 3D o real-time, ma una cornice analitica per descrivere coerenze e possibili anomalie in dati ambientali storici. Le RFD sostituiscono l'uguaglianza rigida delle dipendenze funzionali con vincoli di similarità e possono ammettere eccezioni [2]. Questo le rende adatte a fenomeni rumorosi e influenzati da variabili non osservate.

Gli obiettivi sono: costruire e profilare un dataset pulito; scoprire RFD minime con un algoritmo del corso; misurare supporto, confidenza e lift delle RFD scoperte; verificarne

robustezza temporale; esportare le coppie violanti. Le regole selezionate manualmente restano soltanto un confronto supplementare.

2 Dati e preprocessing

La sorgente è il *Beijing Multi-Site Air Quality Data Set* della UCI [1]. Sono usate le due stazioni disponibili localmente, **Aotizhongxin** e **Changping**, nell'intera copertura comune dal 1 marzo 2013 al 28 febbraio 2017. Dopo il riepilogo dei valori mancanti, le righe incomplete sulle colonne selezionate vengono eliminate senza imputazione. Il dataset pulito contiene 66619 righe e 11 colonne.

Il profiling usa tutte le righe. Per DiMε si costruisce invece una relazione analitica domain-driven: per ogni settimana, stazione e `time_slot` si calcola la mediana di **PM2.5**, **PM10**, **N02**, **O3**, **TEMP** e **WSPM**. Ne risultano 1676 righe, che rappresentano tutte le 66619 osservazioni originarie. La chiave temporale e il numero di righe sorgente sono mantenuti per lineage ma non partecipano alla scoperta.

Tabella 1: Dataset e relazione analitica DiMε

Indicatore	Valore
Righe pulite	66619
Colonne pulite	11
Aotizhongxin	32779
Changping	33840
Righe della relazione DiMε	1676
Attributi di scoperta	8
Coppie nella relazione DiMε	1 403 650

La relazione contiene `station`, `time_slot`, **PM2.5**, **PM10**, **N02**, **O3**, **TEMP**, **WSPM**. Questa scelta preserva sito, contesto intra-giornaliero, inquinanti e vento/temperatura, limitando al contempo il costo quadratico delle matrici delle differenze. Non viene imposto alcun limite alla dimensione del lato sinistro.

3 Profiling descrittivo

Le medie sul dataset orario pulito sono 76.53 per **PM2.5**, 101.95 per **PM10**, 51.51 per **N02** e 56.91 per **O3**. Le correlazioni più forti sono **PM2.5–PM10** (0.874), **TEMP–DEWP** (0.823) e **PM2.5–N02** (0.679). Questi valori sono descrittivi e non costituiscono input o scorciatoie per la scoperta DiMε.




Figura 1: Media giornaliera di PM2.5 per stazione.




Figura 2: Matrice di correlazione sul dataset pulito.

4 RFD discovery algorithm: DiM ϵ

DiM ϵ (*Difference Matrices and ϵ -thresholds*) è l'algoritmo del corso usato come metodo principale [3]. L'input è una relazione, una funzione di distanza e una soglia di similarità per ogni attributo, più una soglia di estensione ϵ per l'errore g_3 . L'output è l'insieme delle RFD minime che soddisfano tali vincoli.

L'implementazione segue i passi dell'algoritmo:

1. costruzione della matrice delle differenze per ogni attributo;

2. derivazione dei pattern di tuple simili e degli insiemi stripped, eliminando i pattern singleton;
3. costruzione level-wise del lattice completo degli otto attributi;
4. generazione dei candidati $X \setminus \{A\} \rightarrow A$ mediante gli insiemi $C^+(X)$;
5. validazione esatta mediante refinement/cardinalità degli insiemi stripped quando non sono ammesse eccezioni;
6. validazione ibrida tramite g_3 , cioè la quota minima di tuple da rimuovere per rendere valida la RFD;
7. applicazione dei bound DiMe ϵ , del pruning dei candidati, del pruning delle chiavi e del controllo di minimalità;
8. join dei nodi compatibili per generare il livello successivo.

Tabella 2: Tracciabilità dei passi DiMe ϵ

Passo implementato	Funzioni principali	Fonte
Matrici delle differenze	<code>build_difference_matrices</code>	Lezione 3, slide 30–31; Definizione 2 [4]
Pattern simili e insiemi stripped	<code>StrippedSimilarSubsets</code>	Lezione 3, slide 32–35; Definizione 3 [4]
Lattice completo e C^+	<code>_initialize_candidates</code> , <code>_generate_next_level</code>	Lezione 3, slide 29–30; Sezione 4 [4]
Refinement e cardinalità	<code>_validate</code>	Lezione 3, slide 36–39; Lemmi 1–2 [4]
g_3 , caso disgiunto e vertex cover	<code>_g3_error</code> , <code>_official_greedy_vertex_cover</code>	Lezione 3, slide 40–41; Sezione 4 [4]
Bound, pruning e RFD minime	<code>_compute_dependencies</code> , <code>_prune_keys</code>	Lezione 3, slide 29–30 e 41; distribuzione ufficiale [6]

Per attributi numerici si usa la differenza assoluta; per `station` e `time_slot` l’uguaglianza. Le soglie `medium` sono: 10 per PM2.5, 15 per PM10, 10 per NO2, 10 per O3, 2 per TEMP e 1 per WSPM. La soglia di estensione è $g_3 \leq 0.10$. Poiché il calcolo generale di g_3 per RFD ibride è NP-completo, il run principale usa l’approssimazione greedy vertex-cover prevista da DiMe ϵ ; il modulo espone anche la modalità esatta di decisione vertex-cover prevista dall’implementazione di riferimento, con limite derivato esclusivamente dalla soglia di estensione richiesta.

Come controllo indipendente, l’algoritmo è stato eseguito sul file `iris.csv` distribuito dagli autori, con gli stessi parametri `maxthr=1`, `maxcovthr=1` e modalità greedy. Il JAR ufficiale riporta 5 RFD: $\emptyset \rightarrow B$, $E \rightarrow D$, $E \rightarrow A$, $E \rightarrow C$ e $A, C \rightarrow D$. L’implementazione Python restituisce esattamente lo stesso insieme, senza regole mancanti o aggiuntive; registra inoltre, nello stesso ordine logico, $g_3 = 0.0133, 0, 0.0267, 0.0200$ e 0.0933 . Il JAR non esporta il g_3 per singola regola, quindi il confronto esatto verificabile riguarda cardinalità e identità delle dipendenze.

5 Metriche e analisi post-discovery

Le metriche pairwise non determinano quali regole DiMε scopre, ma servono a ordinarle e interpretarle dopo la scoperta:

$$\text{support} = \frac{\text{antecedent pairs}}{\text{total pairs}}, \quad \text{confidence} = \frac{\text{valid pairs}}{\text{antecedent pairs}}.$$

La baseline è la confidenza media su 30 permutazioni seeded del RHS e

$$\text{lift} = \frac{\text{confidence}}{\text{baseline confidence}}.$$

Le prime quattro RFD vengono inoltre analizzate con 30 bootstrap bilanciati, split temporale 2013–2016/2016–2017, finestre mensili e coppie violanti. Queste analisi sono successive a DiMε e non modificano il risultato della scoperta.

6 Risultati

DiMε visita tutti gli 8 livelli del lattice, valida 960 candidati e scopre 5 RFD, tutte minime e con supporto positivo.

Tabella 3: Top RFD scoperte da DiMε

Regola	g_3	Support	Conf.	Lift
<code>station, PM10, NO2, O3, TEMP → WSPM</code>	0.092	0.00161	0.899	1.163
<code>PM2.5, PM10, NO2, O3, TEMP → WSPM</code>	0.074	0.00127	0.889	1.155
<code>station, PM2.5, NO2, O3, TEMP → WSPM</code>	0.087	0.00138	0.887	1.151
<code>station, PM2.5, PM10, O3, TEMP → WSPM</code>	0.081	0.00127	0.887	1.147
<code>time_slot → WSPM</code>	0.047	0.24955	0.858	1.113

Quattro delle cinque regole raggiungono confidenza elevata ma supporto pairwise molto basso: devono essere interpretate come regolarità specifiche di regioni locali e dense dello spazio di similarità. `time_slot → WSPM` è la RFD scoperta più generale, perché ha supporto 0.24955, pur con un lift più contenuto. La differenza tra g_3 e violation rate non è una contraddizione: g_3 conta tuple da rimuovere, mentre la confidenza conta coppie valide.

Il bootstrap conferma la stabilità locale delle quattro RFD selezionate. Per la prima regola la confidenza media è 0.930 e il lift medio 1.207, con intervallo empirico al 95% del lift [1.171, 1.244]. Le altre tre mostrano lift medio tra 1.198 e 1.203. Nello split temporale, la prima regola passa da confidenza 0.888 nel train a 0.937 nel test; le altre passano da circa 0.866–0.873 a 0.948–0.953. Il supporto resta tuttavia inferiore a 0.003: questa limitazione deve accompagnare qualsiasi interpretazione.




Figura 3: Continuous profiling mensile delle RFD scoperte da DiMe.

Le coppie con violazione più forte sono esportate per le prime due RFD. Per **station**, PM10, NO2, O3, TEMP $\rightarrow$ WSPM, il gruppo più numeroso tra le 200 coppie selezionate è Changping, gennaio 2016, **afternoon**: 9 coppie, differenza media di WSPM 2.22 e massima 3.40. Una violazione può riflettere anomalie, problemi di qualità del dato o eventi non osservati; non viene automaticamente classificata come errore.




Figura 4: Concentrazione delle coppie violanti per mese e stazione.

Le precedenti regole manuali e le varianti binned sono mantenute soltanto nei CSV supplementari dedicati. Non costituiscono il metodo principale e non vengono presentate come output della scoperta.

7 Discussione e conclusioni

Il progetto usa DiMe come algoritmo di scoperta del corso, senza limiti artificiali alla dimensione del LHS e senza sostituirlo con una ricerca custom di combinazioni. La riduzione computazionale avviene sul dato: un'aggregazione domain-driven usa tutte le osservazioni e preserva stazione e fascia oraria. Questa scelta rende trattabile il costo pairwise quadratico, ma sposta il significato delle RFD dal livello orario al profilo settimanale.

I risultati mostrano cinque regolarità minime orientate verso WSPM. Il lift superiore a 1 indica un vantaggio rispetto alla baseline permutata, ma il margine è moderato e quattro regole hanno supporto molto basso. Non si formulano quindi leggi ambientali o affermazioni causali. L'UDT resta concettuale; le RFD servono per consistency profiling e continuous profiling. Future estensioni dovrebbero verificare la sensibilità a diverse granularità temporali e soglie, oppure usare DOMINO quando l'obiettivo sia inferire le soglie anziché fornirle come input.

Riferimenti bibliografici

- [1] S. Chen. *Beijing Multi-Site Air Quality* [Dataset]. UCI Machine Learning Repository, 2017. DOI: <https://doi.org/10.24432/C5RK5G>
- [2] L. Caruccio, V. Deufemia, and G. Polese. Relaxed Functional Dependencies – A Survey of Approaches. *IEEE Transactions on Knowledge and Data Engineering*, 28(1):147–165, 2016.
- [3] L. Caruccio, V. Deufemia, and G. Polese. Mining relaxed functional dependencies from data. *Data Mining and Knowledge Discovery*, 34(2):443–477, 2020. DOI: <https://doi.org/10.1007/s10618-019-00667-7>
- [4] L. Caruccio, V. Deufemia, and G. Polese. Lattice-based Discovery of Hybrid Relaxed Functional Dependencies (Discussion Paper). In *SEBD 2020*, CEUR Workshop Proceedings, Vol. 2646, 2020. <https://ceur-ws.org/Vol-2646/24-paper.pdf>
- [5] KDIID course. *Lecture 3: Relaxed Functional Dependencies*. Course material, slides 29–41.
- [6] DASTLab. *DiMe Software Repository*. Official JAR, datasets, and replication README. <https://dastlab.github.io/dime/>